

Les données sur le COVID19 ... à interpréter avec prudence

On n'a jamais eu sans doute autant de données nationales et mondiales sur une maladie. Et autant de commentaires et de décisions publiques. Or tout repose sur un processus qu'on connaît mal et qui produit à travers le monde des chiffres dont les gouvernements s'emparent pour édicter règles, contrôles et contraintes. Est-on bien sûr de ce dont on parle ?

Les données ne sont jamais autre chose qu'une **production humaine**, et résultent donc d'un **processus de fabrication**. De plus, les « données numériques » ne représentent qu'une infime partie du savoir. Il ne faut donc pas les « sur-valoriser », même si elles sont indispensables.

Illustration tirée de : Jay Forrester, « System Dynamics and the Lessons of 35 Years », 1991




Figure 4 Decreasing information content in moving from mental to written to numerical data bases.

Les données sont un produit social

Les données numériques (les chiffres !) sont un « produit » social, et doivent donc être regardées comme telles. Bien entendu, indépendamment des « secrets » de fabrication (qui devraient toujours être dévoilés), il faut aussi traiter de questions techniques concernant la mesure, la représentativité, la robustesse, les classifications et nomenclatures utilisées etc..

En outre, il conviendrait de s'interroger sur la représentation partielle livrée par les données chiffrées et la présence fréquente de biais plus ou moins majeurs (au fait, qui mesure et pourquoi ?).

D'où une catégorisation classique des données que j'enseignais jadis : il y a des mesures directes, d'autres indirectes, exhaustives ou fruit d'enquêtes, physiques ou subjectives (opinions), sans oublier l'effet d'aubaine, quand on utilise des données tirées d'un processus non statistique (comme des dossiers fiscaux ou administratifs, faits pour tout autre chose !)

La réflexion sur les **biais de mesure ou de représentativité** est à ce niveau tout aussi importante que celle sur la **sociologie de la production d'informations**, ou même sur celle de la **représentation sociale** des phénomènes observés. Rappelons-nous quand même que les « comptes » (et donc la maîtrise des données) sont des instruments de puissance (« *Les comptes de la puissance - Histoire de la comptabilité nationale et du plan* ». F. Fourquet, ed. Recherche, 1980).

Positivité et incidence : que mesure-t-on ?

A travers la crise du Covid19, des questions m'ont naturellement saisi : que mesure-t-on, comment, que signifient les indicateurs choisis, comment sont-ils calculés, etc..

On s'est récemment interrogés par exemple sur les résultats des tests. De quoi s'agit-il ? Depuis le 13 mai, il s'agirait en France de la remontée de données de 600 laboratoires environ (laboratoires de ville et établissements hospitaliers concernant le SARS-COV2) enregistrés dans le SI-DEP (*Système d'Informations de DEPistage*). Donc toute comparaison avec les données antérieures (données des trois laboratoires centralisateurs de prélèvements (France métropolitaine et DOM) : Eurofins Biomnis, Cerba) et INOVIE n'est guère crédible, et n'a pas de sens. Et naturellement ils ne représentent pas du tout les mêmes volumes de tests (on passe d'un maximum de 12 000/jour à 220 000/jour).


Qui teste-t-on ?

A ce niveau les choses sont moins claires. Théoriquement on trouve ici les tests des hôpitaux (donc des cas « *suspects* »), ceux des campagnes de dépistage et du contrôle des clusters, et ceux découlant de la démarche volontaire des gens. Autrement dit a priori nous avons affaire à une grande diversité, non documentée dans les publications statistiques, sur la nature même de ce qu'on mesure. Mais si, a posteriori, on peut toujours vérifier la représentativité des personnes testées (groupe d'âge, CSP, signes cliniques éventuels), encore faut-il pouvoir en tirer des enseignements, ce que je n'ai jamais lu.

En outre, dans le temps, pour un territoire donné, et d'un territoire à l'autre, la politique de test (et les pratiques des patients en réclament) n'ont aucune raison d'être stables. L'ampleur et la nature des tests peut changer considérablement.

Les quatre biais

Nous disposons donc d'une statistique hebdomadaire (mais aussi quotidienne, en semaine glissante, etc..) du nombre de tests réalisés (environ 1 million en semaine 35) et du nombre de personnes testées (autour de 900 000). Sur cet ensemble le taux de positivité (des personnes) était de 4,4 % globalement en France.



Ce taux - qui manifestement augmente depuis une dizaine de semaines - mesure le pourcentage de personnes testées positives par rapport au nombre de tests.


- Si une personne est testée positive puis négative, la première PCR positive est conservée. Autrement dit, compte tenu de ce qu'on sait du nombre de « *faux positifs* », ce taux doit être probablement surestimé. Mais on peut penser que ce biais est constant.

- Autre biais, celui relatif aux tests eux-mêmes. Selon les laboratoires eux-même, on aurait à la fois des faux positifs et des faux négatifs, dans proportions significatives. Alors qu'on nous parle souvent des 20 à 40 % de faux positifs, le laboratoire BioGroup indique de son côté que sur 10 prélèvements effectués sur des patients COVID+, 3 ressortent avec un test RT-PCR négatif. Ce qui donne une fiabilité médiocre et inhabituelle.

- Au surplus la notion même de « négatif » ou de « positif » (blanc ou noir, oui ou non..) est elle-même sujette à discussion, l'important (médicalement) étant la charge virale. Autrement dit, la charge virale moyenne « transportée » par les citoyens testés n'est pas mesurée, or, disent certains, c'est cela qui est important. Ce que vous et moi pouvons comprendre...

- Ce qui relativise singulièrement le taux de positivité qui subit donc déjà au moins trois biais importants, avant ce dernier, pourtant fondamental. En effet, on nous explique que l'amplification pratiquée actuellement (30 à 35 cycles d'amplification) peut amener « à *considérer comme positif un patient qui a peu de chance de transmettre la charge virale dont il est porteur à son entourage* » (Frédéric Cotton, chef du service biochimie clinique au laboratoire universitaire de Bruxelles). Or on ne teste plus du tout les mêmes personnes qu'en mars ou avril, où les tests s'appliquaient aux malades des hôpitaux. Autrement dit, on ne sait pas si la contagiosité ou la circulation virale est véritablement révélée par ces données...

Bien entendu, si « stratégie de test il y a », on peut donc s'interroger sur ce que représentent vraiment les résultats. Un examen des pratiques de nos voisins nous amène à douter de leur comparabilité internationale. Ainsi, il semble que les allemands ciblent les personnes malades, à risque, ou de retour de zones considérées comme marquées par une forte circulation du virus. L'Espagne de son côté détaille dans une note une véritable méthodologie dont l'objectif est clairement de tester « *toute personne soupçonnée d'infection par le SARS-COV-2 aura une PCR1 (ou une autre technique de diagnostic moléculaire jugée appropriée) dans les 24 premières heures.* » (Estrategia de Deteccion Precoz, Vigilancia y Control de COVID-19, Actualizado 7 de septiembre de 2020). La stratégie décline par ailleurs la question des cas-contact. Reste à savoir si on fait plus, et si oui selon quelle méthode.



Autrement dit, la **notion même de taux de positivité n'a pas le même sens ici et là**. Or, malheureusement, c'est à partir de leur analyse (évolution, niveau) et de leur comparaison dans le temps et l'espace, qu'on prend des décisions de politique sanitaire. Ce qui laisse prévoir des décisions potentiellement inadéquates, mais ce qui est presque pire, une « représentation erronée » de l'évolution comparative de la maladie.


Le taux d'incidence objet de toutes les attentions..

Reste que cet indicateur (la positivité) est régulièrement commenté par les médias alimentés par les communiqués et les statistiques publiées par Santé Publique France. Avec une interprétation permanente en termes de propagation du virus, et de risque épidémique. On « compte » le nombre de nouveaux cas journalier qu'on confronte aux performances de nos voisins (!), on évalue le taux de positivité qu'on compare tout autant. Or, répétons-le, rien indique, bien au contraire que les « cas » mesurés soient comparables..

Or on ne se contente pas de publier les tests positifs (qui varient naturellement en fonction du nombre de tests), le taux de positivité (dont on a vu qu'il découle à la fois des personnes visées par les tests, du mode de calcul de la positivité, etc.) mais on calcule aussi ce qu'on appelle « *le taux d'incidence* ». Un chiffre « magique » symbolique du danger... qu'on prétend analyser sur la base départementale (il faut bien n'est-ce pas s'appuyer sur des découpages administratifs).

Or que signifie ce fameux taux d'incidence ? Il s'agit du « *nombre de nouvelles personnes testées positives pour un tests de SARS-COV2, rapporté à la population pour 100 000 habitants* » (par semaine généralement). On sait que ce taux dépend de la capacité de « localiser » la résidence des patients, et de « remonter » les données

convenablement.. On nous dit en effet que les chiffres sont réajustés régulièrement en raison du fait que « *le délai de remontée des tests peut excéder 9 jours dans certains cas* ».



Le taux est donc censé nous **donner une idée de la circulation du virus** dans la population résidente. Ainsi, chaque jour on dénombre d'une part les positifs résidents les positifs non résidents (publiés ou non) qu'on réimpute à leur département de résidence. Bien entendu, les tests concernent une proportion variable de non-résidents, sans rapport direct précis (mesuré ?) avec leur présence. En outre l'ampleur du « tourisme » selon les régions n'est pas identique. Rappelons ici que la fréquentation touristique maximale peut, dans certaines communes, démultiplier considérablement la population présente en période estivale ou hivernale. Cette méthode d'imputation n'est pas sans problème ; elle est même « analytiquement » curieuse. Si, en effet elle indique ce qui pourrait être une circulation virale dans la population « locale », elle préjuge

curieusement de la nature même de celle-ci, à laquelle donc, les non résidents ne contribueraient pas « statistiquement ».

En fait, on ne mesure pas la **présence territoriale** du virus (mais à quoi dès lors le rapporter puisqu'il faudrait estimer la population « présente », chose possible en Corse, difficile sur le continent), mais sa présence dans la population résidente. On ne mesure donc pas la circulation dans la population testée à un moment donné et un endroit déterminé, mais pour une population résidente, quelque soit sa localisation au moment du test. Ce choix n'a bien évidemment pas la même conséquence sur l'ensemble du territoire, ce qui, avouons-le, génère un biais supplémentaire.

Les conséquences des biais multiples et des difficultés de des données sont assez évidentes. Faute d'une information visant à mesurer la circulation virale dans la population - ce que seuls des tests pratiqués sur un échantillon représentatif de la population permet - on s'acharne à tirer des leçons de cas, taux de positivité et d'incidence, qui résultent plus des politiques de test que de l'activité du virus lui-même. Une politique sanitaire n'est en effet pas une stratégie de suivi épidémiologique. Nous avons eu ce débat dans d'autres domaines. Ainsi, par exemple, l'exploitation de données de contrôle de temps de conduite des conducteurs routiers ne produit pas une information « comparable » à ce que donne une enquête sur un échantillon représentatif.

La mortalité


Le suivi de la mortalité est une autre affaire. On sait - par exemple à travers le suivi de la mortalité routière - que la mesure du nombre de décès en lien avec une causalité (maladie, accident) nécessite une définition rigoureuse. **Il faut donc déterminer ce qu'est « un mort » et la causalité du décès.**

Ainsi, jusqu'en 2005, en France, un mort (routier) était considéré comme tel s'il décédait sur le coup ou dans les 6 jours après l'accident. La période désormais est fixée à 30 jours.. sans pour autant être appliquée de manière totalement exhaustive. Ainsi, les séries statistiques ne sont pas homogènes et on a dû, pour la période de 1952 à 2004, estimer « *le nombre de personnes tuées à 30 jours à partir du nombre des personnes tuées à 6 et 3 jours, par application d'un coefficient majorateur* ». La série statistique ne découle donc pas d'observations identiques mais de ce qu'on appelle une **rétropolation**, chose courante, mais souvent négligée dans les commentaires. Ainsi donc, la mortalité n'est pas une notion aussi simple que cela à étudier.

Pour le Covid, l'expérience française nous amené assez vite à en saisir la difficulté.

Première donnée publiée, la **mortalité à l'hôpital**. Il s'agit ici des patients, cas confirmés de Covid19, décédés dans les établissements de santé de France. Ces données ne sont pas exhaustives, Santé Publique France rappelant que « *le nombre d'établissements déclarant varie au cours du temps* ».

On sait que c'est à ce chiffre qu'on a dû par la suite ajouter les décès en « **établissements sociaux et médico-sociaux** », dont




l'ampleur cumulée est de l'ordre de 1/3 des décès recensés et imputés au Covid19.

L'indicateur était donc et demeure partiellement biaisé, et ne recense pas les décès hors du système de soins ou « médico-social ». Ce qui bien entendu ne constitue pas un biais indépendant de la politique de soins, l'accès à l'hôpital pouvant varier selon les périodes.

Une seconde approche consiste non pas à chercher un lien causal entre mortalité et maladie, mais de tirer des données des données des **certificats de décès...** pour les communes ayant une transmission dématérialisée avec l'INSEE. Un simple tracé des données observées ainsi permet de « jauger » la **surmortalité** éventuelle.

On s'intéresse alors non pas à une mortalité absolue, mais à l'excès (ou non) de morts qui peut être calculé par rapport au passé ou




par rapport à un nombre calculé par un modèle (voir <https://www.euromomo.eu/graphs-and-maps/>).

Pratiquement en France, « les excès estimés (par l'Insee) sont établis sur un ensemble de 3000 communes, qui représentent **77 % de la mortalité nationale** » mais variable selon les départements. Gros biais donc. Ces données sont compilées par ailleurs avec un certain délai (variable). Ce même calcul est réalisé par de nombreux pays. Il permet d'estimer (!) la surmortalité due à une épidémie. Ces chiffres peuvent être déclinés par tranche d'âge.

Le sens..

Comme on le voit, la « communication » des données ne prend guère le temps d'en relativiser le sens, d'autant que souvent des données quotidiennes, naturellement très fluctuantes localement et singulièrement pour de petits ordres de grandeur, sont présentées. Or il y a bien à s'interroger non seulement sur ce qu'on mesure (positifs, positivité, décès, malades etc.) et sur le sens à donner à ce qu'on observe. Il est par exemple évident que le « **taux d'incidence** », présenté comme un **signe de circulation virale est un indicateur très imparfait, fortement biaisé** et nous observons (semaine 35) qu'il n'est pas sans rapport avec l'ampleur des tests (activité analytique).


Taux d'incidence et activité analytique en France semaine 35



Or, on communique pour l'heure essentiellement sur l'indicateur le moins précis, et dont l'élaboration ne relève ni d'un « recensement »

ni d'une approche statistique, mais d'un processus complexe non documenté, et strictement incomparable d'un pays à l'autre.

En revanche, l'indicateur le plus significatif n'est pas commenté : les données de mortalité relative ne sont plus jamais mises en avant. Il est toujours possible de s'interroger sur les raisons de cette stratégie de communication, consciente ou non.



Conclure ?

La conclusion de ce petit voyage dans l'univers des « données » relatives au Covid19 est plutôt sévère : on compare et commente des données dont la nature est imparfaitement documentée, et dont la

production relève parfois de stratégies différentes. En outre nous ne disposons pas d'une approche statistique de la maladie, c'est à dire s'intéressant au suivi d'échantillons représentatifs de la population (par zone géographique) qui permettrait de mesurer quelque chose de significatif. En outre, l'objet même de la mesure est discuté et discutable. La positivité étant manifestement un indicateur ne faisant pas l'unanimité.

Or de tout cela - c'est à dire de données non maîtrisées - on va tirer des décisions publiques, qu'on dira fondées sur un éclairage objectif. Ce qui n'est pas vrai. Nous touchons donc là à une question majeure pour la vie en société.

*« Est-ce que le phare qui éclaire la route conduit l'automobile ? »,
Auguste Detoeuf*