


23 septembre 2020



Du nombre de tests PCR et de l'utilité des données statistiques

La compréhension des données relatives au Covid19 repose sur des indicateurs régulièrement publiés (Geodes, et Data.gouv). Nous avons déjà discuté de la signification même des données ainsi construites et diffusées (voir : « *Les données sur le COVID19 ... à interpréter avec prudence* », 10 septembre 2020 sur LinkedIn)

Or l'évolution de la politique de test et des pratiques sociales conduit à constater une dégradation possible de l'utilité des données relatives aux tests PCR.

1. Il apparaît qu'il n'y a pas de politique structurée de prélèvement au niveau des laboratoires de ville, mais qu'on a cherché « à faire le plus de tests possibles ».
2. Cette logique fondée sur le volontariat peut produire - *par hasard* - une représentativité convenable des personnes testées par rapport à la population de référence. Pour autant, les données ne sont pas redressées pour assurer cette représentativité.

3. On note en outre l'absence de différenciation des personnes testées plusieurs fois.

4. Cette logique de l'*open-bar*, a pu aboutir, depuis peu, dans certaines régions, à des retards dans la production des résultats altérant l'utilité sanitaire et médicale des tests, mais aussi des données de test. En effet, on enregistre les tests et leur résultats non à la date du prélèvement ou de l'analyse, mais de la communication des résultats. Or le délai entre tests et résultat s'allonge dans certaines régions, et n'est donc pas constant ni dans l'espace ni dans le temps.

5. On a pu constater d'ailleurs que le même « aléa » lié au délai administratif (ou de production) est observé également en matière hospitalière.

6. Les politiques « locales » de test - comme les campagnes de dépistage estivales - ou les tests sur ordonnance médicale peuvent modifier sensiblement la structure de la population testée.


7. On constate finalement une grande disparité du nombre de tests en laboratoires (autrement appelés « *activité analytique* ») rapportés à la population.

8. Pour la semaine 28, l'activité analytique pour 100 000 habitants varie entre 127 (Charente) et 2195 (Mayotte), avec une moyenne de 503 (médiane 447). Cette grande dispersion des pratiques peut refléter des situations différentes, y compris dans la même région (Cas de la Corse avec 637 en Corse du Sud et 375 en Haute Corse).


9. On s'interroge donc sur les causes de ces écarts, qu'elles relèvent des conséquences de la perception locale de la maladie, de la politique des ARS ou des laboratoires, ou encore de la sociologie des populations. Pour autant, les éléments rendus publics ne permettent nullement de les estimer.

10. A titre d'exemple, un département comme le Gers a connu une variation très importantes du nombre de tests pratiqués par semaine (activité analytique pour 100 000 habitants) :


11. Gers = activité analytique (Tests/100000 habitants)



12. La Corse du sud connaît un profil très différent....



13. ... lui-même différent de celui du département de Haute Corse (niveau et évolution).



14. De tels écarts ne sont actuellement ni expliqués ni justifiés, et aucune conséquence n'en est - semble-t-il tiré.


15. Or, ce sont ces données qui permettent d'étudier la circulation du virus à partir de l'activité analytique. (taux d'incidence, taux de positivité).

16. Ces profils différents peuvent avoir une incidence sur le suivi épidémique. Et encore sont-ils compilés sur une base administrative arbitraire et relativement large : le département.

17. L'analyse sommaire des données publiées conduit généralement à chercher à repérer des relations (statistiques) entre les « cas » en amont (relevés à partir des tests) et des indicateurs hospitaliers (hospitalisations, entrée en réanimation, décès, sorties), en prenant en compte un certain décalage temporel.

18. Or, les données hospitalières souffrent, on a pu le voir, du même défaut que les données sur les tests puisqu'elles sont non exhaustives, non redressées, et souffrent de délais variables de communication, les chiffres étant repris « à la date de déclaration ».

19. Le cas de l'Essonne est caricatural de ce type de biais.




20. Par conséquent, le lien temporel possible entre les « cas », les hospitalisations et les différentes suites possibles, est statistiquement biaisé, et singulièrement en cas de données départementales quotidiennes.

21. Ces données quotidiennes doivent donc être lissées pour pouvoir être valablement interprétées compte tenu de la variabilité des tests pratiqués et des résultats publiés selon le jour de la semaine.

22. Il faut aussi remarquer que les stratégies de soin interviennent dans la détermination ce lien, tout comme d'ailleurs l'évolution du virus lui-même.


A. Dans un premier temps (jusqu'à mi-mai) en effet on a peu détecté, et dirigé les malades « sérieux » vers les urgences. Il n'y a donc pas de lien entre tests et hospitalisations.

B. En outre le ratio « CFR (*Case Fatality Ratio*)» c'est à dire le nombre de décès rapporté au nombre de cas est élevé à la fois en raison du faible nombre de cas détectés et de l'absence de soin efficace (sauf dans certains hôpitaux). Le graphique ci-après fait apparaître clairement l'effet probable de cette stratégie « de fait » en France.



B. Dans un second temps, et progressivement, la politique de test PCR se met en place. On assiste alors à une augmentation régulière du nombre de tests, jusqu'à dépasser en moyenne 2 tests par millier d'habitants. Un nombre plus du double de celui des italiens, et supérieur à celui de l'Allemagne et de l'Espagne.

C. D'où l'interrogation sur le sens à donner aux cas positifs observés et aux taux de positivité et d'incidence.



D. Nous ne revenons pas ici sur le lien existant entre le nombre de cycles d'amplification des PCR (CT) et la « matérialité » des virus (morts au delà d'un certain degré d'amplification). Des critiques vives existent contre des amplifications excessives (>35) et le sens donné alors à la notion même de cas (degré de contagiosité et/ou potentialité de maladie).

E. Cette question « scientifique » interfère directement avec ce qu'on peut vouloir faire des données de cas, et le rapport difficile à construire dans le temps avec les admissions à l'hôpital (ou les soins, par ailleurs non recensés), et a fortiori la mortalité.

F. Pour le dire autrement, la mesure des cas positifs étant indifférenciée, il y a d'une part une marge d'erreur générale, mais aussi une absence de qualification possible de la contagiosité et/ou de la gravité potentielle, qui est liée au nombre de cycle d'amplification, nombre qui n'est pas indiqué.

G. Ces remarques doivent en outre prendre en compte que le virus évolue dans le temps, et que ses mutations ont une incidence, incidence qu'il

est plus difficile d'examiner statistiquement en situation de biais multiples sur les données. (Voir par exemple « *Effects of a major deletion in the SARS-CoV-2 genome on the severity of infection and the inflammatory response: an observational cohort study* » , Barnaby E Youg et Alii, Lancet, Aout 2020)

23. De tels biais statistiques peuvent exister dans nombre d'autres domaines. Pour autant on essaie généralement soit de les éliminer, soit de les prendre en compte dans l'analyse en corrigeant certaines données, et en les complétant (ajout d'informations, segmentation, données supplémentaires). Ce n'est pas fait dans le cas du Covid19 en France.

24. A tout le moins on pourrait attendre que le calcul du « *taux d'incidence* » du virus soit effectué à partir de données prenant en compte les délais d'analyse et surtout la structure de la population testée (représentativité), et donc découle d'un redressement statistique.

25. Le taux de reproduction du virus qui est calculé (R_0), subit naturellement les mêmes biais.

26. De même, la prise en compte du nombre de cycle d'amplification aurait pu être pris en compte.

27. On peut ainsi s'étonner que les données soient indistinctement produite pour des objectifs de suivi sanitaire - et alors pourquoi ne sont-elles pas affinées et plus explicatives ? - et pour des objectifs de statistique générale (épidémiologique) auquel cas il aurait fallu s'imposer d'en assurer la représentativité et la significativité, ce qui n'est pas le cas.

28. Ces remarques laissent à penser que l'absence de clarté de la stratégie sanitaire a influé directement sur l'organisation de la production des données, qui

sont des données de suivi médical (voir par exemple ; <https://solidarites-sante.-gouv.fr/ministere/article/donnees-personnelles-et-cookies>).

29. Il serait donc utile qu'une discussion prenne place sur la production des données et leur utilisation tant sur le plan médical que statistique.